

Overview del proyecto — Predicción de riesgo de deserción estudiantil en Colombia

Concurso Datos al Ecosistema 2026 · Uso interno del equipo

1. Estado del arte en Colombia — ¿Ya existe algo parecido?

La respuesta corta es: sí existen soluciones, pero ninguna resuelve el problema desde donde nosotros lo vamos a atacar. Esto es clave para justificar la novedad del proyecto.

Lo que ya existe

SPADIES / SNIES — el sistema oficial del MEN El gobierno colombiano tiene el SPADIES (Sistema para la Prevención y Análisis de la Deserción), integrado al SNIES desde 2018. Es la fuente de todos los datos de deserción del país. El problema: es un sistema de *reporte histórico*, no de predicción. Te dice cuántos desertaron el semestre pasado, no quiénes van a desertar el próximo.

u-planner (startup chilena, opera en Colombia) Plataforma IA que trabaja con universidades privadas como Los Andes, EAFIT, Cooperativa, Bolivariana y Uniminuto, y con la Gobernación de Cundinamarca. Analiza comportamiento individual del estudiante dentro del sistema de la universidad: asistencia, conexiones a plataformas virtuales, rendimiento por materia. Su fortaleza es el dato individual interno. Su limitación: es una solución *privada, intramuros*, que requiere que la IES tenga sus datos integrados — no escala a nivel nacional ni trabaja con datos abiertos.

Antivirus para la Deserción (ONG colombiana) Organización sin ánimo de lucro enfocada en intervención social. Su enfoque es humano y comunitario, no tecnológico-predictivo.

Investigaciones académicas recientes (2024-2025) Hay estudios con modelos ML sobre datasets de una sola IES. El más reciente (Banquez et al., 2025, revista Inge CuC) usó LightGBM sobre 104.147 registros de *una universidad colombiana* no identificada, con 27 variables. Otro usó modelos de Monte Carlo sobre datos históricos del SPADIES para proyectar tendencias nacionales agregadas. Lo que tienen en común: trabajan con datos de *una sola institución* o con *agregados nacionales sin granularidad territorial*.

El hueco que nadie ha llenado

Ninguna solución existente combina las tres cosas al mismo tiempo:

1. **Datos abiertos públicos** (no datos privados de una IES)
2. **Granularidad territorial** (por municipio y programa, no solo nacional)
3. **Orientada a la acción de política pública** (no a consejeros de una sola universidad)

Eso es exactamente lo que nosotros vamos a construir.

2. Executive Summary — Qué hay hoy y qué cambia con el proyecto

El problema hoy

Colombia tiene una tasa de deserción acumulada de ~23% en el nivel universitario y ~33% en técnico/tecnológico. Eso equivale a que 1 de cada 3 estudiantes que entra al sistema no termina. El MEN lo sabe. Las universidades lo saben. Pero la herramienta que tienen — el SPADIES — solo les dice cuánto pasó, no dónde va a pasar.

Cómo se toman decisiones hoy:

El MEN publica la tasa nacional de deserción del año anterior. Una secretaría de educación regional revisa el dato y concluye que "hay que hacer algo". No sabe si el problema está en las IES públicas o privadas, en qué programas, en qué municipios, ni en qué momento del ciclo académico. El recurso de intervención (bienestar, becas, acompañamiento) se distribuye de forma genérica o por intuición política.

Qué cambia con el proyecto

Nuestro sistema analiza la combinación de variables territoriales, socioeconómicas y académicas disponibles en datos públicos y genera un **score de riesgo de deserción prospectivo** por programa × municipio × semestre. Eso permite priorizar dónde intervenir antes de que ocurra la deserción.

Cómo se tomarían decisiones con el proyecto:

La plataforma muestra al equipo de bienestar de una universidad en Buenaventura que el programa de Ingeniería Industrial tiene probabilidad alta de repunte de deserción en el próximo semestre. Las señales: es un municipio con alta pobreza multidimensional, el programa tiene tasas históricas altas en primeros semestres, y el índice de cobertura en educación media en la zona es bajo (lo que predice estudiantes con menos preparación previa). El equipo activa intervención preventiva: contacta a los estudiantes de primer y segundo semestre, gestiona apoyos de bienestar y ajusta la carga académica de los cursos con mayor reprobación histórica.

El ejemplo concreto (antes vs. después):

	Sin el proyecto (hoy)	Con el proyecto
Dato disponible	"En 2023 la deserción universitaria fue 8.08% nacional"	"El programa X en el municipio Y tiene 74% de probabilidad de aumento en 2025-2"
Quién actúa	Nadie con urgencia — es un dato pasado	Consejero estudiantil la semana antes de matrícula
Cómo actúa	Plan genérico de bienestar para todos	Intervención dirigida a los 40 estudiantes de mayor riesgo
Resultado esperado	Reacción después de la deserción	Prevención antes de que ocurra

3. Fuentes de datos y enfoque realista

Este es el punto donde más proyectos fallan: proponen datos que no existen o que tienen calidad insuficiente. Aquí somos explícitos.

Fuentes confirmadas en datos.gov.co y portales públicos

Fuente	Qué aporta	Formato	Calidad
SNIES / MEN — Matrícula por programa	IES, programa, nivel, municipio, género, año, semestre, total matriculados	CSV estructurado	Alta — serie 2010-2023
SPADIES 3.0 — Tasas de deserción	Tasa de deserción anual y acumulada por IES, nivel, área y período	CSV / consulta web	Alta — serie comparable desde 2018
MEN — Estadísticas preescolar, básica y media por municipio	Deserción, aprobación, reprobación y cobertura por municipio 2011-2023	CSV estructurado	Alta — actualizado a 2023
DANE — Pobreza Multidimensional municipal	IPM por municipio — proxy de contexto socioeconómico del estudiante	CSV	Alta
ICFES — Resultados Saber 11 por municipio	Puntaje promedio por municipio — proxy de preparación académica previa	CSV público	Media-alta
DANE — Proyecciones de población	Población por edad y municipio — para normalizar tasas	CSV	Alta

Variables que vamos a construir como features del modelo

Estas no vienen "listas" de una sola fuente — las construimos cruzando las anteriores:

- **Tasa histórica de deserción** del programa en los últimos 4 semestres
- **Índice de pobreza** del municipio de la IES
- **Cobertura en educación media** del municipio (proxy de preparación del estudiante entrante)
- **Puntaje promedio Saber 11** del municipio
- **Tipo de IES** (pública vs. privada) y carácter (universidad, tecnológica, técnica)
- **Área de conocimiento** del programa (las ingenierías tienen patrones distintos a las ciencias sociales)
- **Modalidad** (presencial vs. virtual — las virtuales tienen deserción estructuralmente mayor)
- **Semestre de mayor riesgo** (1er y 2do semestre concentran ~60% de la deserción)

Lo que explícitamente NO vamos a usar

- Datos individuales de estudiantes (no están disponibles en datos abiertos y tienen restricción de privacidad)
- Datos internos de IES (notas, asistencia, pagos) — requieren convenios institucionales que no tenemos tiempo de gestionar
- Datos posteriores a 2023 — el SPADIES cierra estadísticas con rezago de 1-2 semestres

Decisión técnica clave: trabajar solo con datos post-2018

El SPADIES tuvo una actualización metodológica en 2018 (SPADIES 3.0) que hace que los datos anteriores no sean comparables con los nuevos. Trabajar con la serie 2018-2023 nos da 5 años de historia limpia y comparable — suficiente para entrenar un modelo con solidez.

Riesgo principal de datos: granularidad vs. privacidad

Los datos del SNIES están disponibles a nivel de programa $\times$ IES $\times$ municipio, pero **sin identificación individual de estudiantes**. Esto es una ventaja para la privacidad y una limitación para la predicción: nuestro modelo predice riesgo a nivel de *cohorte / programa / territorio*, no de persona. Eso es correcto para una herramienta de política pública, que es exactamente lo que el concurso pide.

Resumen ejecutivo para alineación del equipo

Qué construimos: un sistema de alerta temprana de deserción estudiantil que opera a nivel territorial (municipio $\times$ programa $\times$ semestre), usando únicamente datos públicos disponibles en datos.gov.co y portales del MEN/DANE.

Qué lo hace nuevo: nadie ha cruzado los datos del SNIES con contexto socioeconómico territorial y preparación académica previa para hacer predicción prospectiva orientada a política pública — las soluciones existentes son intramuros (una IES) o agregadas (solo nivel nacional).

Qué entregamos al concurso: modelo ML + dashboard visual interactivo donde una secretaria de educación puede ver el mapa de Colombia coloreado por riesgo de deserción, filtrar por departamento, tipo de IES y área de conocimiento, y recibir alertas accionables para el próximo semestre.

Quién hace qué:

- *ML Engineer (tú):* pipeline de datos, feature engineering, modelo predictivo
- *Analista de datos:* exploración descriptiva, validación de variables, narrativa de hallazgos
- *Diseñadora UX/UI:* dashboard interactivo, sistema de alertas visuales, presentación final

Próximo paso concreto: descargar los datasets del SNIES y MEN, explorar columnas disponibles y confirmar que los cruces son posibles con las llaves que identificamos (código municipio DANE, código SNIES de programa).